

Chapter 2

Xuan

2020 年 9 月 21 日

1 条件互信息

在有三个变量的情况下，符号 x_i 与符号对 (y_j, z_k) 之间的互信息量定义为

$$I(x_i; y_j, z_k) = \log \frac{p(x_i | y_j, z_k)}{p(x_i)}$$

条件互信息量是在给定 z_k 条件下， x_i 与 y_j 之间的互信息量，定义为

$$I(x_i; y_j | z_k) = \log \frac{p(x_i | y_j, z_k)}{p(x_i | z_k)}$$

结合上述公式可写为

$$I(x_i; y_j, z_k) = I(x_i; z_k) + I(x_i; y_j | z_k)$$

1.1 相关公式推导

$$\begin{aligned} I(X; Y | Z) &= \sum p(x, y, z) \log \frac{p(x, y | z)}{p(x | z) p(y | z)} \\ &= \sum_z D(p(x, y | z) || p(x | z) p(y | z)) * p(z) \end{aligned} \tag{1}$$

$$\begin{aligned} \frac{p(x, y | z)}{p(x | z) p(y | z)} &= \frac{p(x | y, z) p(y | z) p(x)}{p(x) p(x | z) p(y | z)} \\ &= \frac{p(x, y, z)}{p(x) p(y, z)} * \frac{p(x)}{p(x | z)} \end{aligned} \tag{2}$$

将 (2) 带入 (1)

$$(1) = \sum p(x, y, z) \log \frac{p(x, y, z)}{p(x)p(y, z)} - \sum p(x, y, z) \log \frac{p(x|z)p(z)}{p(x)p(z)} \quad (3)$$

$$\begin{aligned} \sum p(x, y, z) \log \frac{p(x|z)p(z)}{p(x)p(z)} &= \sum_{x, y, z} (p(x, z) \log \frac{p(x, z)}{p(x)p(z)}) p(y|x, z) \\ &= \sum_{x, z} \sum_y \\ &= \sum_{x, z} p(x, z) \log \frac{p(x, z)}{p(x)p(z)} \sum_y p(y|x, z) \end{aligned} \quad (4)$$

将 (4) 带入 (3)

$$\begin{aligned} (3) &= \sum p(x, y, z) \log \frac{p(x, y, z)}{p(x)p(y, z)} - \sum p(x, z) \log \frac{p(x, z)}{p(x)p(z)} \\ &= I(X; Y, Z) - I(X; Z) \\ &= H(X) - H(X|Y, Z) - (H(X) - H(X|Z)) \\ &= H(X|Z) - H(X|Y, Z) \end{aligned} \quad (5)$$

2 信息不增性

对于马尔可夫链 $X \rightarrow Y \rightarrow Z$ ，有

$$I(X; Z) \leq I(Y; Z)$$

2.1 公式证明

$$\left. \begin{aligned} I(X; Y, Z) &= I(X; Y) + I(X; Z|Y) \\ I(X; Z|Y) &= \sum_y D(p(x, z|y) || p(x|y)p(z|y)) p(y) = 0 \end{aligned} \right\} I(X; Y, Z) = I(X; Y) \quad (6)$$

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \quad (7)$$

$$p(x, y, z) = p(y)p(x|y)p(z|y) \iff p(x, z|y) = p(x|y)p(z|y)$$

综上所述， $I(X; Y) = I(X; Y, Z) \geq I(X; Z)$

2.2 文氏图证明

见 chapter2.jpg

3 连续信源的熵和互信息

3.1 连续信源熵

$$H_c(x) = - \int_{-\infty}^{\infty} p_x(x) \log p_x(x) dx \geq 0$$

3.2 能量确定条件下, $\int_{-\infty}^{\infty} x^2 p(x) dx$ 在高斯分布情况下最大化熵率

$$H_c(x) = - \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-m)^2}{2\sigma^2}} \log \left[\frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-m)^2}{2\sigma^2}} \right] dx \quad (8)$$

证明过程见 homework1

3.3 范围确定条件下, 均匀分布最大化熵率

变量 X 的幅度取值限定在 $[a, b]$, 则有 $\int_a^b p_x(x) dx = 1$, 当任意 $p_x(x)$ 符合平均条件,

$$p_x(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{other} \end{cases}$$

时, 信源达到最大熵

$$\begin{aligned} H_c(x) &= - \int_a^b \frac{1}{b-a} \log \frac{1}{b-a} dx \\ &= \log(b-a) \end{aligned} \quad (9)$$

4 熵的一部分性质

4.1 香农辅助定理

对任意的 n 维概率矢量 $P = (p_1, p_2, \dots, p_n)$ 和 $Q = (q_1, q_2, \dots, q_n)$, 如下不等式成立

$$H(p_1, p_2, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i \leq - \sum_{i=1}^n p_i \log q_i$$

该式表明, 用不等的概率分布来编码会使熵增

4.2 条件熵小于无条件熵

条件熵小于信源熵: $H(Y|X) \leq H(Y)$ 。当且仅当 y 和 x 相互独立时, $p(y|x) = p(y)$, 取等号。

两个条件下的信源熵小于一个条件下的信源熵, 即 $H(Z|x, y) \leq H(Z|Y)$, 当且仅当 $p(z|x, y) = p(z|y)$ 时取等号。

联合熵小于信源熵之和: $H(X, Y) \leq H(X) + H(Y)$ 。当且仅当两个集合相互独立时取等号。

5 离散有记忆信源的序列熵

对于由两个符号组成的联合信源, 有下列结论:

1. $H(X_1, X_2) = H(X_1) + H(X_2|X_1) = H(X_2) + H(X_1|X_2)$ (Chain Rule)
2. $H(X_1) \geq H(X_1|X_2), H(X_2) \geq H(X_2|X_1)$

考虑离散平稳信源, 有下列结论成立:

1. $H(X_L/X^{L-1})$ 是 L 的单调非增函数
2. $H_L(X) \geq H(X_L|X^{L-1})$ ($H_L(X)$ 为平均符号熵)
3. $H_L(X)$ 是 L 的单调非增序列

4. 当 $L \rightarrow \infty$ 时, 有 $H_\infty(X) := \lim_{L \rightarrow \infty} H_L(X) = \lim_{L \rightarrow \infty} H(X_L | X_1, X_2, \dots, X_{L-1})$,
其中, $H_\infty(X)$ 称为极限熵, 又称为极限信息量

对于齐次, 遍历的马尔可夫链, 其状态 s_i 由 $(x_{i_1}, \dots, x_{i_m})$ 唯一确定, 因此有 $p(x_{i_{m+1}} | x_{i_m}, \dots, x_{i_1}) = p(x_{i_{m+1}} | s_i)$, 可以得到在这种情况下极限熵为 $H_\infty(x) = \sum_i p(s_i) H(X | s_i)$, 其中 $p(s_i)$ 是马尔可夫链的稳态分布。